

Lista 1 de Macro III

Shai Vaz

Exercício 1

Letra a

Definições de cada P.E.:

Ruído Branco

É um P.E. u_t com as seguintes características:

$$\mathbb{E}[u_t] = 0$$

$$\mathbb{V}[u_t] = \sigma^2$$

$$\mathbb{COV}(u_t, u_{t-k}) = 0, \forall t, k$$

Frequentemente isso é realizado utilizando uma distribuição normal padrão, ou seja, $u_t \sim \mathcal{N}(0, 1)$. O ruído branco é um processo puramente aleatório, não apresentando nenhum nível de persistência – isto é, o que ocorre no período t não influencia o que ocorre em nenhum outro período posterior (ou anterior).

Média Móvel de ordem 1, MA(1)

É um P.E. y_t tal que:

$$y_t = \mu + u_t + \theta_1 u_{t-1}$$

Onde μ é a média do processo, θ_1 é um parâmetro que mede o grau de persistência do choque do período $t - 1$ para o período t , e u_t, u_{t-1} são ruídos brancos, representando choques imprevisíveis. Assim, o MA(1) apresenta autocorrelação positiva, mas apenas entre períodos consecutivos.

Média Móvel de grau 3, MA(3)

Semelhante ao MA(1), mas com os choques u_t , representados por ruídos brancos, persistindo por 3 períodos ao invés de apenas 1. Assim, pode ser escrito da forma seguinte:

$$y_t = \mu + u_t + \theta_1 u_{t-1} + \theta_2 u_{t-2} + \theta_3 u_{t-3}$$

Esse processo apresenta autocorrelação do período t com até três períodos de distância dele, mas essa autocorrelação cessa quando é medida para mais do que 3 períodos.

Autoregressivo de ordem 1, AR(1)

Escrito sob a forma de uma equação de diferenças de primeira ordem, tem uma redução suave da persistência dos choques entre os períodos, gradualmente convergindo a 0 (satisfeitas algumas hipóteses):

$$y_t = \phi_0 + \phi_1 y_{t-1} + u_t$$

Supondo $t \rightarrow \infty$, y_0 finito e $|\phi_1| < 1$, podemos escrever um AR de ordem 1 como um MA de ordem infinita:

$$y_t = \frac{\phi_0}{1 - \phi_1} + u_t + \phi_1 u_{t-1} + \phi_1^2 u_{t-2} + \phi_1^3 u_{t-3} + \dots$$

Vemos que há um grau de autocorrelação com todos os (infinitos) períodos, mas o efeito de um choque em t vai diminuindo de intensidade conforme se distancia dele no tempo. Isto é, há persistência, mas ela converge suavemente a 0, sem uma queda brusca como nos processos de tipo média móvel de ordem finita.

Letra b

Os processos de ruído branco não servem para modelar muitos MGDs, pois são puramente aleatórios, e espera-se que haja algum grau de persistência nas variáveis macroeconômicas. Já os processos do tipo média móvel têm autocorrelação que zera de forma abrupta, após certa defasagem de períodos. Mas na maior parte das variáveis macroeconômicas espera-se que a autocorrelação gradualmente vá reduzindo, em uma lenta convergência a 0. Assim, o tipo de processo mais utilizado na modelagem do MGD de variáveis macroeconômicas é o AR(1), pois ele gera séries cujos choques tem efeitos duradouros, mas com intensidade cada vez menor, o que é muito mais realista.

Letra c

De imediato, vê-se pelo parâmetro ϕ_1 de cada processo que a persistência é muito maior no processo a_t do que no processo x_t , isto é, que os choques resuntantes do ruído branco permanecem afetando períodos futuros de forma muito mais intensa no primeiro processo do que no segundo. Podemos ser mais precisos, analisando a chamada Função de Resposta a Impulso. Primeiro, representamos cada processo em sua forma MA(∞):

$$a_t = u_t + 0.9u_{t-1} + 0.9^2 u_{t-2} + 0.9^3 u_{t-3} + \dots$$

$$x_t = u_t + 0.3u_{t-1} + 0.3^2 u_{t-2} + 0.3^3 u_{t-3} + \dots$$


Portanto temos que as funções de resposta a impulso são:

$$\text{FRI}_{a_t} = \delta_k^{a_t} = \frac{\partial a_{t+k}}{\partial u_t} = 0.9^k$$

$$\text{FRI}_{x_t} = \delta_k^{x_t} = \frac{\partial x_{t+k}}{\partial u_t} = 0.3^k$$

Assim, vemos que o impulso de um u_t teria um efeito muito mais persistente nas variáveis do modelo caso utilizássemos o processo a_t como choque, ao invés do processo x_t . Podemos visualizar essa diferença plotando um gráfico das F.R.I. (de forma contínua, para simplificar). Em azul temos a FRI do processo a_t , e em roxo a FRI do processo x_t . Vemos que o impacto de uma variação em u_t cai muito mais rápido no processo x_t .

```
curve(0.3^x, from = 0, to = 15, col = "purple", ylab = "F.R.I. contínua", lwd = 2)
curve(0.9^x, add=TRUE, col = "blue", lwd=2)
```



Exercício 2

Letra a

```
library("sidrar")
library("tidyr")
library("ggplot2")
library("dplyr")
library("knitr")
library("forecast")
library("mFilter")
```

Importamos os dados das contas nacionais trimestrais:

```
cod_sidra <- "/t/1621/n1/all/v/all/p/all/c11255/all/d/v584%202"
dados <- sidrar::get_sidra(api = cod_sidra)
```

```
## All others arguments are desconsidered when 'api' is informed
```

Organizando os dados, separando os setores em colunas e transformando em série temporal.

```
df=cbind(dados[,c(5,10,12)])
colnames(df)=c("valor","tri","setor")
df2 = pivot_wider(df, names_from = setor, values_from = valor)
df3=ts(df2[,-1],start=c(1996,1),frequency = 4)
```

Organizando cada variável em um df separado.

```
# PIB
y_pm=df3[, "90707"]
# VA - AGROPECUARIA
ys_agr=df3[, "90687"]
# VA - INDUSTRIA
ys_ind=df3[, "90691"]
# VA - SERVIÇOS
ys_ser=df3[, "90696"]
# CONSUMO DAS FAMILIAS
yd_cf=df3[, "93404"]
# CONSUMO DO GOVERNO
yd_cg=df3[, "93405"]
# FBCF (INVESTIMENTO)
yd_fbcf=df3[, "93406"]
# EXPORTAÇÕES
yd_exp=df3[, "93407"]
# IMPORTAÇÕES
yd_imp=df3[, "93408"]
```

Letra b

Veremos em **preto** a série original e em **laranja** a tendência estimada pelo filtro HP.


PIB

```
# Aplica o filtro HP
c = mFilter(y_pm, filter="HP")
# salva o componente tendencial
y_pmt = fitted(c)
# salva o componente ciclico
y_pmc = resid(c)
```

```
#y_pmt vs y_pm

ggplot() +
  theme_minimal()+
  geom_line(data = y_pmt,
            aes(x=time(y_pmt),
                y=y_pmt),
            linewidth = 1,
            color = "orange") +
```

```
geom_line(data = y_pm,
          aes(x=time(y_pm),
              y=y_pm),
          linewidth = 1,
          color = "black") +
labs(
  x="",
  y="",
  title = "Estimação do Componente de Tendência: PIB"
)
```



VA da Agropecuária

```
# Aplica o filtro HP
c = mFilter(ys_agr, filter="HP")
# salva o componente tendencial
ys_agrt = fitted(c)
# salva o componente ciclico
ys_agrc = resid(c)
```

```
#ys_agrt vs ys_agr
```

```
ggplot() +
```


```

theme_minimal()+
geom_line(data = ys_agrt,
          aes(x=time(ys_agrt),
              y=ys_agrt),
          linewidth = 1,
          color = "orange") +

geom_line(data = ys_agr,
          aes(x=time(ys_agr),
              y=ys_agr),
          linewidth = 1,
          color = "black") +

labs(
  x="",
  y="",
  title = "Estimação do Componente de Tendência: VA da Agropecuária"
)

```



VA da Indústria

```

# Aplica o filtro HP
c = mFilter(ys_ind, filter="HP")
# salva o componente tendencial

```

```
ys_indt = fitted(c)
# salva o componente ciclico
ys_indc = resid(c)
```


```
#ys_indt vs ys_ind
```

```
ggplot() +
  theme_minimal()+
  geom_line(data = ys_indt,
            aes(x=time(ys_indt),
                y=ys_indt),
            linewidth = 1,
            color = "orange") +

  geom_line(data = ys_ind,
            aes(x=time(ys_ind),
                y=ys_ind),
            linewidth = 1,
            color = "black") +

  labs(
    x="",
    y="",
    title = "Estimação do Componente de Tendência: VA da Indústria"
  )
```

Estimação do Componente de Tendência: VA da Indústria



VA dos Serviços

```
# Aplica o filtro HP
c = mFilter(ys_ser, filter="HP")
# salva o componente tendencial
ys_sert = fitted(c)
# salva o componente ciclico
ys_serc = resid(c)
```


```
#ys_sert vs ys_ser
```

```
ggplot() +
  theme_minimal()+
  geom_line(data = ys_sert,
            aes(x=time(ys_sert),
                y=ys_sert),
            linewidth = 1,
            color = "orange") +

  geom_line(data = ys_ser,
            aes(x=time(ys_ser),
                y=ys_ser),
            linewidth = 1,
            color = "black") +

  labs(
    x="",
    y="",
    title = "Estimação do Componente de Tendência: VA dos Serviços"
  )
```


Estimação do Componente de Tendência: VA dos Serviços




Consumo das Famílias

```
# Aplica o filtro HP  
c = mFilter(yd_cf, filter="HP")  
# salva o componente tendencial  
yd_cft = fitted(c)  
# salva o componente ciclico  
yd_cfc = resid(c)
```

```
#yd_cft vs yd_cf  
  
ggplot() +  
  theme_minimal()+  
  geom_line(data = yd_cft,  
            aes(x=time(yd_cft),  
                y=yd_cft),  
            linewidth = 1,  
            color = "orange") +  
  
  geom_line(data = yd_cf,  
            aes(x=time(yd_cf),  
                y=yd_cf),  
            linewidth = 1,  
            color = "black") +
```

```
labs(
  x="",
  y="",
  title = "Estimação do Componente de Tendência: Consumo das Famílias"
)
```



Consumo do Governo

```
# Aplica o filtro HP
c = mFilter(yd_cg, filter="HP")
# salva o componente tendencial
yd_cgt = fitted(c)
# salva o componente ciclico
yd_cgc = resid(c)
```

```
#yd_cgt vs yd_cg

ggplot() +
  theme_minimal()+
  geom_line(data = yd_cgt,
            aes(x=time(yd_cgt),
                y=yd_cgt),
            linewidth = 1,
```


```

    color = "orange") +

geom_line(data = yd_cg,
          aes(x=time(yd_cg),
              y=yd_cg),
          linewidth = 1,
          color = "black") +

labs(
  x="",
  y="",
  title = "Estimação do Componente de Tendência: Consumo do Governo"
)

```



Formação Bruta de Capital Fixo

```

# Aplica o filtro HP
c = mFilter(yd_fbcf, filter="HP")
# salva o componente tendencial
yd_fbcft = fitted(c)
# salva o componente ciclico
yd_fbcfc = resid(c)

```


```
#yd_fbcft vs yd_fbcf

ggplot() +
  theme_minimal()+
  geom_line(data = yd_fbcft,
            aes(x=time(yd_fbcft),
                y=yd_fbcft),
            linewidth = 1,
            color = "orange") +

  geom_line(data = yd_fbcf,
            aes(x=time(yd_fbcf),
                y=yd_fbcf),
            linewidth = 1,
            color = "black") +

  labs(
    x="",
    y="",
    title = "Estimação do Componente de Tendência: F.B.C.F."
  )

```



Exportações

```
# Aplica o filtro HP
c = mFilter(yd_exp, filter="HP")
# salva o componente tendencial
yd_expt = fitted(c)
# salva o componente ciclico
yd_expc = resid(c)
```


```
#yd_expt vs yd_exp

ggplot() +
  theme_minimal()+
  geom_line(data = yd_expt,
            aes(x=time(yd_expt),
                y=yd_expt),
            linewidth = 1,
            color = "orange") +

  geom_line(data = yd_exp,
            aes(x=time(yd_exp),
                y=yd_exp),
            linewidth = 1,
            color = "black") +

  labs(
    x="",
    y="",
    title = "Estimação do Componente de Tendência: Exportações"
  )
```

Estimação do Componente de Tendência: Exportações




Importações

```
# Aplica o filtro HP  
c = mFilter(yd_imp, filter="HP")  
# salva o componente tendencial  
yd_impt = fitted(c)  
# salva o componente ciclico  
yd_impc = resid(c)
```

```
#yd_impt vs yd_imp  
  
ggplot() +  
  theme_minimal()+  
  geom_line(data = yd_impt,  
            aes(x=time(yd_impt),  
                y=yd_impt),  
            linewidth = 1,  
            color = "orange") +  
  
  geom_line(data = yd_imp,  
            aes(x=time(yd_imp),  
                y=yd_imp),  
            linewidth = 1,  
            color = "black") +
```

```
labs(
  x="",
  y="",
  title = "Estimação do Componente de Tendência: Importações"
)
```



Letra c

```
merged_cicles = ts.union(
  y_pmc,
  ys_agrc,
  ys_indc,
  ys_ser,
  yd_cfc,
  yd_cgc,
  yd_fbcfc,
  yd_expc,
  yd_impc,
  dframe = TRUE)
```

```
merged_cicles %>%
  summarise(across(everything(), sd)) %>%
  rename(
```

```

"PIB" = y_pmc,
"VA agro" = ys_agrc,
"VA ind" = ys_indc,
"VA serv" = ys_serc,
"Consumo fam" = yd_cfc,
"Consumo gov" = yd_cgc,
"FBCF" = yd_fbcfc,
"Export" = yd_expc,
"Import" = yd_impdc
) %>%
pivot_longer(cols = everything(), values_to = "sd") %>%
mutate(sd_y = sd/sd[1]*100) %>%
select(!sd) %>%
arrange(sd_y) %>%
knitr::kable(digits = 2,
              col.names = c("Componente Cíclico",
                           "SD Proporcional (%)" ),
              caption = "Desvio padrão como % do desvio padrão do PIB")

```

Table 1: Desvio padrão como % do desvio padrão do PIB

Componente Cíclico	SD Proporcional (%)
Consumo gov	72.69
VA serv	89.72
PIB	100.00
Consumo fam	113.18
VA ind	124.75
VA agro	221.49
FBCF	273.90
Export	335.70
Import	505.79

Portanto, vemos que são menos voláteis que o PIB às séries de **Consumo do Governo e Valor Agregado dos Serviços**. Por outro lado, são mais voláteis que o PIB (em ordem crescente de volatilidade) as séries de **Consumo das Famílias, Valor Agregado da Indústria, Valor Agregado da Agropecuária, FBCF (Investimento), Exportações e Importações**.

Os fatos estilizados para o caso americano, para as variáveis da ótica da demanda, indicam que **consumo privado e consumo do governo** são menos volátil que o PIB, enquanto **investimento, exportações e importações** são mais voláteis. Para a maior parte das séries isso é válido também para a experiência brasileira, mas diferenças se apresentam em relação à americana no caso do **consumo privado**, que é mais volátil aqui.

Letra d

Função de Autocorrelação dos Ciclos

```

# Variáveis de Ciclos
cycles = ts.union(
  y_pmc,

```



```

ys_agrc,
ys_indc,
ys_serc,
yd_cfc,
yd_cgc,
yd_fbcfc,
yd_expc,
yd_imp)

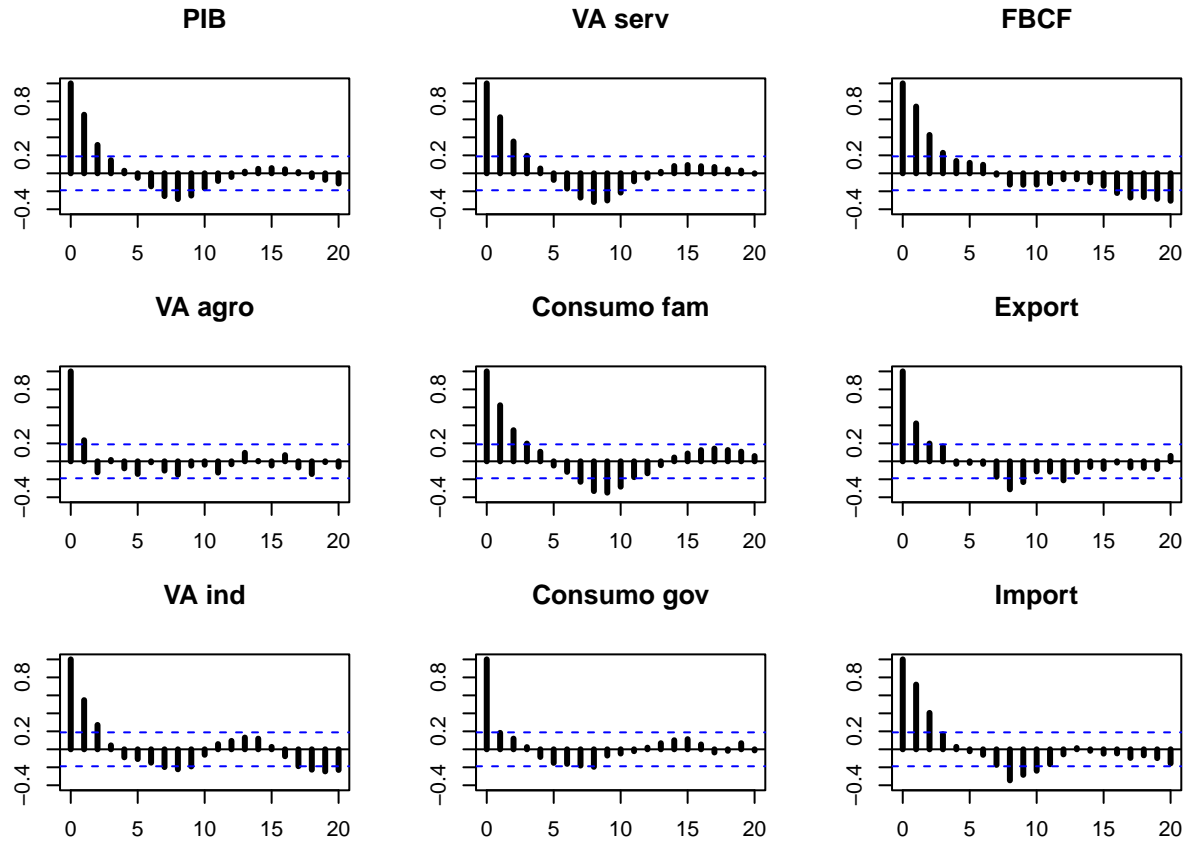
# Titles
t_cicles = c(
  "PIB",
  "VA agro" ,
  "VA ind" ,
  "VA serv",
  "Consumo fam",
  "Consumo gov",
  "FBCF",
  "Export",
  "Import"
)

par(fig = c(0.05, 0.95, 0.05, 0.95),
     mar = c(2, 3, 4, 2))

layout(matrix(1:9, ncol=3))

for(i in 1:9){
  a = Acf(cicles[,i], plot = FALSE)
  plot(a,
       lwd = 3,
       ylim = c(-0.4, 1),
       main = t_cicles[i])
}

```



```
# A função Acf não pde ser utilizada no summarise
# Fazemos uma versão que retorna um valor numérico único
acf1 <- function(ts){
  as.numeric(
    as.character(
      Acf( ts,
           plot = FALSE,
           lag.max = 1)[1])[1])
}
```

```
merged_cicles %>%
  summarise(across(everything(), acf1)) %>%
  rename(
    "PIB" = y_pmc,
    "VA agro" = ys_agrc,
    "VA ind" = ys_indc,
    "VA serv" = ys_serc,
    "Consumo fam" = yd_cfc,
    "Consumo gov" = yd_cgc,
    "FBCF" = yd_fbcfc,
    "Export" = yd_expc,
    "Import" = yd_imp
  ) %>%
  pivot_longer(cols = everything(), values_to = "acf1") %>%
  knitr::kable(digits = 3,
    col.names = c("Componente Cíclico",
```

```
"ACF(1)" ,
caption = "Autocorrelação de Primeira Ordem de cada ciclo")
```

Table 2: Autocorrelação de Primeira Ordem de cada ciclo

Componente Cíclico	ACF(1)
PIB	0.652
VA agro	0.234
VA ind	0.547
VA serv	0.624
Consumo fam	0.624
Consumo gov	0.183
FBCF	0.743
Export	0.422
Import	0.720

As séries “mais persistentes”, a partir de uma análise visual, são **PIB**, **VA dos Serviços**, **Consumo das Famílias** e sobretudo **FBCF**.

Letra e

Calculando o coeficiente de correlação entre os componentes cíclicos e o PIB.

```
merged_cicles %>%
  cor() %>%
  as_tibble(rownames = NA) %>%
  slice(1) %>%
  rename(
    "PIB" = y_pmc,
    "VA agro" = ys_agrc,
    "VA ind" = ys_indc,
    "VA serv" = ys_serc,
    "Consumo fam" = yd_cfc,
    "Consumo gov" = yd_cgc,
    "FBCF" = yd_fbcfc,
    "Export" = yd_expc,
    "Import" = yd_impdc
  ) %>%
  pivot_longer(cols = everything(), values_to = "cor") %>%
  arrange(desc(cor)) %>%
  knitr::kable(digits = 3,
    col.names = c("Componente Cíclico",
      "Cor(. , PIB)"),
    caption = "Coeficiente de correlação com o ciclo do PIB")
```

Table 3: Coeficiente de correlação com o ciclo do PIB

Componente Cíclico	Cor(. , PIB)
PIB	1.000

Componente Cíclico	Cor(. , PIB)
VA serv	0.924
VA ind	0.875
Consumo fam	0.872
FBCF	0.848
Import	0.776
Consumo gov	0.485
Export	0.299
VA agro	0.250

Vemos que as séries mais correlacionadas com o PIB são **VA dos Serviços, VA da Indústria, Consumo das Famílias e FBCF**. Também vemos que nenhuma variável é anticíclica, pois todos os coeficientes de correlação são positivos. Agora vamos aos gráficos comparando os componentes cíclicos com o PIB. Veremos em **preto** a série do PIB e em **laranja** a série analisada.

VA Agropecuária

```
ggplot() +
  theme_minimal()+
  geom_line(aes(x=time(y_pmc),
                y=y_pmc),
            linewidth = 1,
            color = "black") +


  geom_line(aes(x = time(y_pmc),
                y = ys_agrc),
            linewidth = 1,
            color = "orange") +

  geom_hline(yintercept = 0) +

  labs(
    x="",
    y="",
    title = "Ciclos: PIB vs VA Agropecuária")
```

```
## Don't know how to automatically pick scale for object of type <ts>. Defaulting
## to continuous.
## Don't know how to automatically pick scale for object of type <ts>. Defaulting
## to continuous.
```

Ciclos: PIB vs VA Agropecuária



As séries aparentam ser pouco correlacionadas entre si. Pode haver algum grau de anticiclicidade, mas não é muito claro pelo gráfico.


VA da Indústria

```
ggplot() +  
  theme_minimal()+  
  geom_line(aes(x=time(y_pmc),  
                y=y_pmc),  
            linewidth = 1,  
            color = "black") +  
  
  geom_line(aes(x = time(y_pmc),  
                y = ys_indc),  
            linewidth = 1,  
            color = "orange") +  
  
  geom_hline(yintercept = 0) +  
  
  labs(  
    x="",  
    y="",  
    title = "Ciclos: PIB vs VA Indústria")
```

Don't know how to automatically pick scale for object of type <ts>. Defaulting

```
## to continuous.
## Don't know how to automatically pick scale for object of type <ts>. Defaulting
## to continuous.
```

Ciclos: PIB vs VA Indústria



A série é claramente altamente correlacionada com o PIB, coincidente e pró-cíclica.

VA dos Serviços

```
ggplot() +
  theme_minimal()+
  geom_line(aes(x=time(y_pmc),
                y=y_pmc),
            linewidth = 1,
            color = "black") +

  geom_line(aes(x = time(y_pmc),
                y = ys_serc),
            linewidth = 1,
            color = "orange") +


  geom_hline(yintercept = 0) +

  labs(
    x="",
```

```
y="",
title = "Ciclos: PIB vs VA Serviços")
```

```
## Don't know how to automatically pick scale for object of type <ts>. Defaulting
## to continuous.
## Don't know how to automatically pick scale for object of type <ts>. Defaulting
## to continuous.
```

Ciclos: PIB vs VA Serviços



A série é altamente correlacionada com o PIB, e apresenta simultaneidade e pró-ciclicidade.

Consumo das Famílias

```
ggplot() +
  theme_minimal()+
  geom_line(aes(x=time(y_pmc),
                y=y_pmc),
            linewidth = 1,
            color = "black") +


  geom_line(aes(x = time(y_pmc),
                y = yd_cfc),
            linewidth = 1,
            color = "orange") +
```

```
geom_hline(yintercept = 0) +

labs(
  x="",
  y="",
  title = "Ciclos: PIB vs Consumo das Famílias")
```

```
## Don't know how to automatically pick scale for object of type <ts>. Defaulting
## to continuous.
## Don't know how to automatically pick scale for object of type <ts>. Defaulting
## to continuous.
```

Ciclos: PIB vs Consumo das Famílias



Aparenta ser uma série simultânea com o PIB, além de pró-cíclica.

Consumo do Governo

```
ggplot() +
  theme_minimal()+
  geom_line(aes(x=time(y_pmc),
    y=y_pmc),
    linewidth = 1,
    color = "black") +

  geom_line(aes(x = time(y_pmc),
```



```


    y = yd_cgc),
    linewidth = 1,
    color = "orange") +

geom_hline(yintercept = 0) +

labs(
  x="",
  y="",
  title = "Ciclos: PIB vs Consumo do Governo")

```

Don't know how to automatically pick scale for object of type <ts>. Defaulting
to continuous.
Don't know how to automatically pick scale for object of type <ts>. Defaulting
to continuous.



A série mostra pouca correlação com o PIB, mas pode-se ver um grau de pró-ciclicidade – diferentemente do fato estilizado no caso da economia americana.

FBCF

```

ggplot() +
  theme_minimal()+
  geom_line(aes(x=time(y_pmc),

```

```

    y=y_pmc),
    linewidth = 1,
    color = "black") +

geom_line(aes(x = time(y_pmc),
    y = yd_fbcfc),
    linewidth = 1,
    color = "orange") +

geom_hline(yintercept = 0) +


labs(
  x="",
  y="",
  title = "Ciclos: PIB vs FBCF (Investimento)")

```

```

## Don't know how to automatically pick scale for object of type <ts>. Defaulting
## to continuous.
## Don't know how to automatically pick scale for object of type <ts>. Defaulting
## to continuous.

```




A série parece razoavelmente correlacionada com o PIB, mas com volatilidade muito maior. Além disso, parece ser coincidente e pró-cíclica.

Exportações

```
ggplot() +  
  theme_minimal()+  
  geom_line(aes(x=time(y_pmc),  
                y=y_pmc),  
            linewidth = 1,  
            color = "black") +  
  
  geom_line(aes(x = time(y_pmc),  
                y = yd_expc),  
            linewidth = 1,  
            color = "orange") +  
  
  geom_hline(yintercept = 0) +  
  
  labs(  
    x="",  
    y="",  
    title = "Ciclos: PIB vs Exportações")
```

```
## Don't know how to automatically pick scale for object of type <ts>. Defaulting  
## to continuous.  
## Don't know how to automatically pick scale for object of type <ts>. Defaulting  
## to continuous.
```

Ciclos: PIB vs Exportações




A série é bastante volátil e é bem difícil apreender muita informação apenas analisando o gráfico. A correlação parece ser baixa, como já vimos.

Importações

```
ggplot() +  
  theme_minimal()+  
  geom_line(aes(x=time(y_pmc),  
                y=y_pmc),  
            linewidth = 1,  
            color = "black") +  
  
  geom_line(aes(x = time(y_pmc),  
                y = yd_imp),  
            linewidth = 1,  
            color = "orange") +  
  
  geom_hline(yintercept = 0) +  
  
  labs(  
    x="",  
    y="",  
    title = "Ciclos: PIB vs Importações")
```

```
## Don't know how to automatically pick scale for object of type <ts>. Defaulting  
## to continuous.  
## Don't know how to automatically pick scale for object of type <ts>. Defaulting  
## to continuous.
```

Ciclos: PIB vs Importações

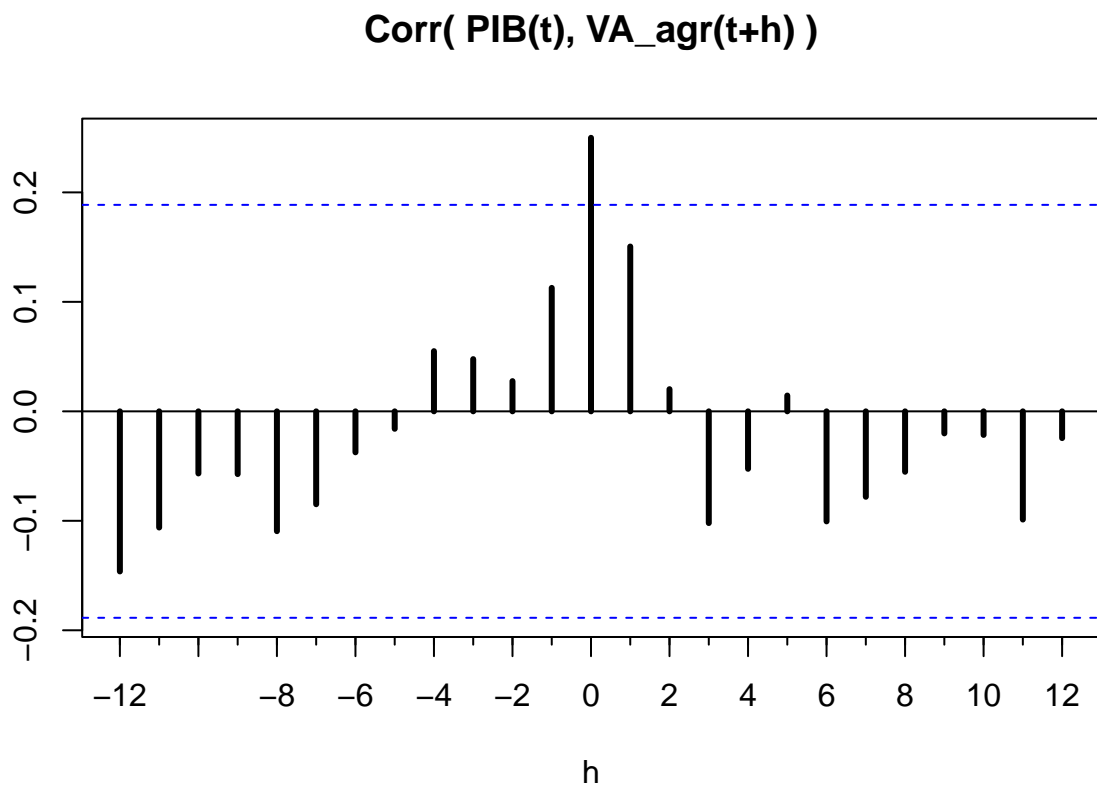


Parece haver certo grau de correlação da série com o PIB, além de pró-ciclicidade e coincidência.

Letra f

VA da Agropecuária


```
par(mar = c(5, 3, 4, 3))
Ccf(ys_agrc,
    y_pmc,
    12,
    lwd=3,
    main="Corr( PIB(t), VA_agr(t+h) )",
    xlab="h")
```



Aqui, a única correlação estatisticamente significativa é a em $h = 0$, que é a correlação simples, que já vimos ser baixa. Portanto, não há forte correlação entre as duas séries.


VA da Indústria

```
par(mar=c(5,3,4,3))
Ccf(ys_indc,
     y_pmc,
     12,
     lwd=3,
     main="Corr( PIB(t), VA_ind(t+h) )",
     xlab="h")
```



Reforça a tese que a série é pró-cíclica e coincidente. ### VA dos Serviços

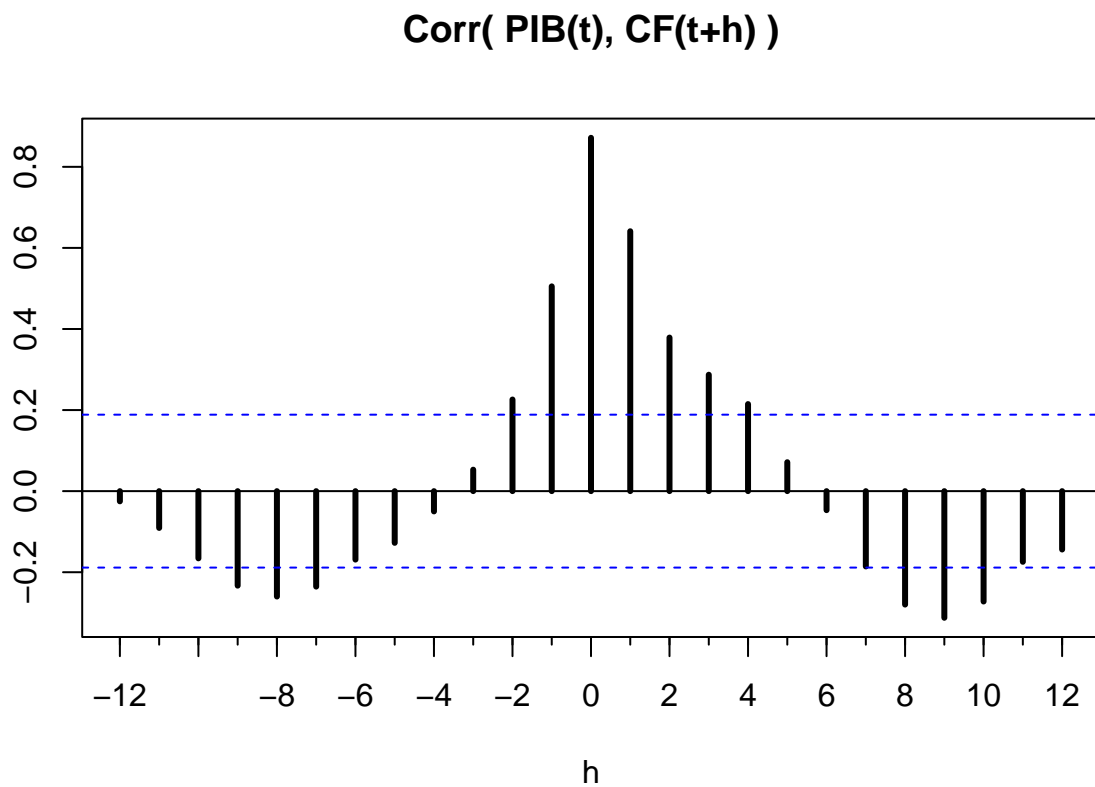
```
par(mar=c(5,3,4,3))
Ccf(ys_serc,
     y_pmc,
     12,
     lwd=3,
     main="Corr( PIB(t), VA_ser(t+h) )",
     xlab="h")
```



Também reforça a hipótese do item anterior.

Consumo das Famílias

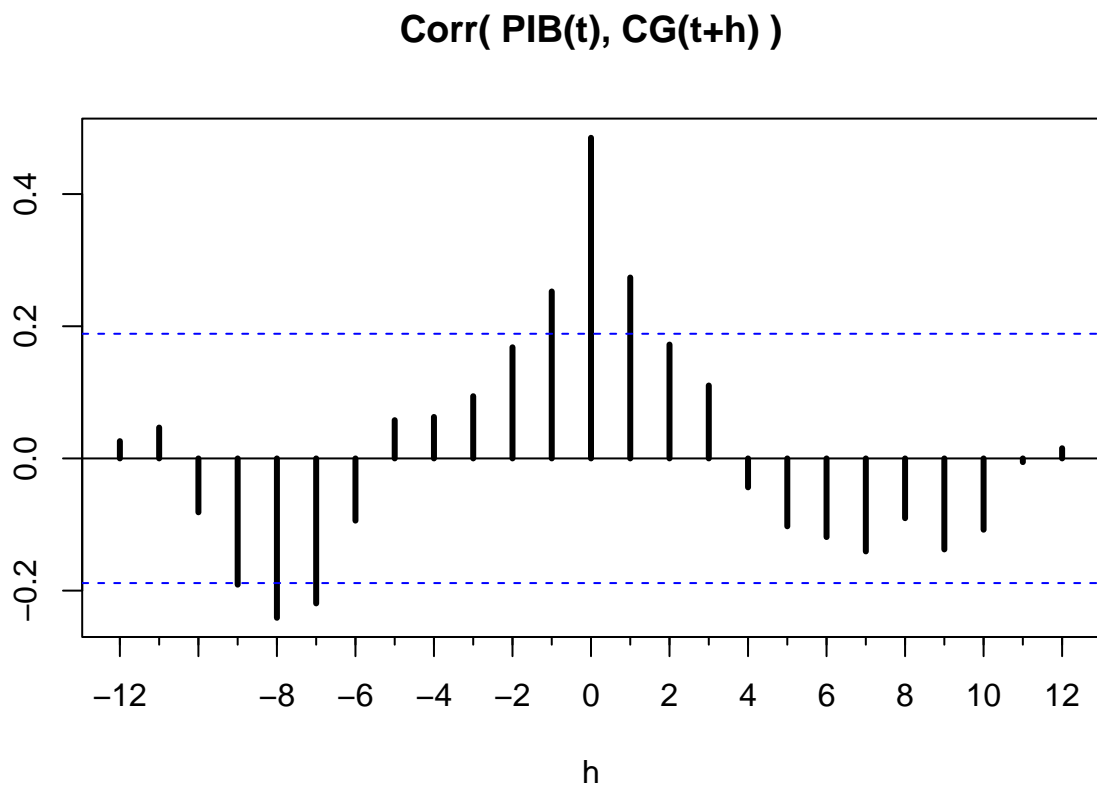
```
par(mar=c(5,3,4,3))
Ccf(yd_cfc,
    y_pmc,
    12,
    lwd=3,
    main="Corr( PIB(t), CF(t+h) )",
    xlab="h")
```

Também parece confirmar a conclusão anterior. Podemos notar também uma leve defasagem.


Consumo do Governo

```
par(mar =c(5,3,4,3))
Ccf(yd_cgc,
    y_pmc,
    12,
    lwd=3,
    main="Corr( PIB(t), CG(t+h) )",
    xlab="h")
```




FBCF (Investimento)

```
par(mar=c(5,3,4,3))
Ccf(yd_fbcfc,
    y_pmc,
    12,
    lwd=3,
    main="Corr( PIB(t), FBCF(t+h) )",
    xlab="h")
```



Confirma as conclusões anteriores, e adiciona a informação de um leve grau de antecedência na série. ###
Exportações

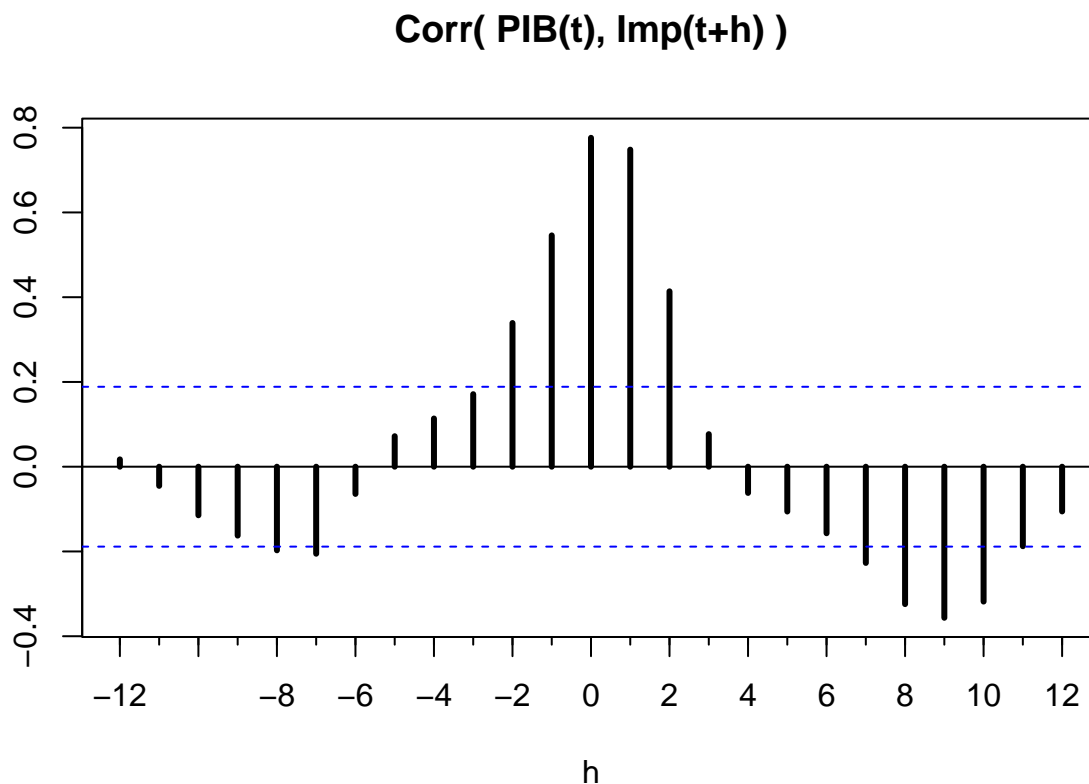
```
par(mar = c(5,3,4,3))
Ccf(yd_expc,
    y_pmc,
    12,
    lwd=3,
    main="Corr( PIB(t), Exp(t+h) )",
    xlab="h")
```



Essa série parece apresentar leve defasagem, mas a correlação sendo baixa, não parece uma informação significativa.

Importações

```
par(mar=c(5,3,4,3))
Ccf(yd_imp,
    y_pmc,
    12,
    lwd=3,
    main="Corr( PIB(t), Imp(t+h) )",
    xlab="h")
```



Fica claro não a conclusão de correlação forte, com pró-ciclicidade, e também percebemos um efeito de persistência cíclica – há efeito positivo forte no curto prazo, mas após 6 períodos há um efeito, mais fraco, negativo de variações no PIB.

Letra g

Essas tabelas já foram feitas em exercícios anteriores, mas apresentar os dados novamente de forma mais organizada e completa.

```
sd_y <- merged_cicles %>%
  summarise(across(everything(), sd)) %>%
  rename(
    "PIB" = y_pmc,
    "VA agro" = ys_agrc,
    "VA ind" = ys_indc,
    "VA serv" = ys_serc,
    "Consumo fam" = yd_cfc,
    "Consumo gov" = yd_cgc,
    "FBCF" = yd_fbcfc,
    "Export" = yd_expc,
    "Import" = yd_imp
  ) %>%
  pivot_longer(cols = everything(), values_to = "sd") %>%
  mutate(sd_y = sd/sd[1])
```

```
acf_1 <- merged_cicles %>%
  summarise(across(everything(), acf1)) %>%
  rename(
    "PIB" = y_pmc,
    "VA agro" = ys_agrc,
    "VA ind" = ys_indc,
    "VA serv" = ys_serc,
    "Consumo fam" = yd_cfc,
    "Consumo gov" = yd_cgc,
    "FBCF" = yd_fbcfc,
    "Export" = yd_expc,
    "Import" = yd_imp
  ) %>%
  pivot_longer(cols = everything(), values_to = "acf1")
```

```
cor_y <- merged_cicles %>%
  cor() %>%
  as_tibble(rownames = NA) %>%
  slice(1) %>%
  rename(
    "PIB" = y_pmc,
    "VA agro" = ys_agrc,
    "VA ind" = ys_indc,
    "VA serv" = ys_serc,
    "Consumo fam" = yd_cfc,
    "Consumo gov" = yd_cgc,
    "FBCF" = yd_fbcfc,
    "Export" = yd_expc,
    "Import" = yd_imp
  ) %>%
  pivot_longer(cols = everything(), values_to = "cor")
```

```
inner_join(sd_y,
  acf_1,
  by = "name") %>%
inner_join(cor_y,
  by = "name") %>%
knitr::kable(digits = 3,
  col.names = c("Componente Cíclico",
    "SD",
    "SD relativo ao PIB",
    "Autocorrelação de grau 1",
    "Correlação instantânea com PIB"),
  caption = "Estatísticas de resumo dos ciclos")
```

Table 4: Estatísticas de resumo dos ciclos

Componente Cíclico	SD	SD relativo ao PIB	Autocorrelação de grau 1	Correlação instantânea com PIB
PIB	2.937	1.000	0.652	1.000
VA agro	6.505	2.215	0.234	0.250
VA ind	3.664	1.247	0.547	0.875

Componente Cíclico	SD	SD relativo ao PIB	Autocorrelação de grau 1	Correlação instantânea com PIB
VA serv	2.635	0.897	0.624	0.924
Consumo fam	3.324	1.132	0.624	0.872
Consumo gov	2.135	0.727	0.183	0.485
FBCF	8.044	2.739	0.743	0.848
Export	9.859	3.357	0.422	0.299
Import	14.854	5.058	0.720	0.776